

Detekcija AI-generisanog teksta

Dimitrije Ignjić RA129/2022

1. Naziv teme

Detekcija AI-generisanog teksta primenom tehnika mašinskog učenja i embeddinga

2. Definicija problema

Svedoci smo da su veliki jezički modeli sve dostupniji za širu upotrebu. Samim tim akademske institucije, novinarske redakcije, digitalne platforme i mnogi drugi suočavaju se sa problemom razlikovanja teksta koji je napisao čovek i teksta koji je generisala računarska inteligencija.

Ovo rešenje direktno odgovara na probleme kao što su:

Akademski integritet - da li je student koristio AI alate za pisanje seminarskog, završnog ili nekog drugog rada i time narušio sistem ocenjivanja

Novinarstvo i mediji - da li je ugrožen kredibilitet izvora informisanja, plasiranjem AI generisanog teksta

Pravni i forenzički kontekst - u sporovima oko autorstva dokumenta

Rešenje ovog problema bi imalo direktan praktičan značaj: pouzdani detektor AI generisanog teksta može biti integrisan u sve gore navedene sisteme.

3. Skup podataka

Javno dostupan skup podataka sa platforme Kaggle:

AI vs Human Text Dataset

<https://www.kaggle.com/datasets/shanegerami/ai-vs-human-text/data>

ATRIBUTI:

Text (tekst instance- članak, esej, odgovor na pitanje)

Generated (ciljno obeležje: 0= napisao čovek, 1 = generisao AI)

SKUP OD SKORO 500.000 INSTANCI.

4. Metodologija

EKSTRAKCIJA OBELEŽJA

Računanje numeričkih obeležja iz teksta koja ne zahtevaju specijalne NLP biblioteke kao što su:

- Prosečna dužina rečenice
- Prosečna dužina reči
- Bogatstvo rečnika (TTR)
- Učestalost interpunkcije
- Varijabilnost dužine rečenica (standardna devijacija)
- TF-IDF vektorizacija teksta (sklearn TfidfVectorizer)
- Word2Vec embedding
-

MODELI KLASIFIKACIJE

Biće implementirana i međusobno upoređena tri modela obrađena na predmetu:

- **KNN**
- **Konvoluciona neuronska mreža**
- **Višeslojna neuronska mreža**

5. Način evaluacije

Sva tri modela se evaluiraju na istom test skupu (80/20 podela trening/test) i porede se sledećim metrikama:

- **Accuracy** — ukupna tačnost klasifikatora
- **Precision, Recall, F1-score** — za obe klase posebno
- **Matrica konfuzije** — prikaz false positive i false negative grešaka
- **K-fold unakrsna validacija** (k=5) — za robusnu procenu performansi

Posebna pažnja posvećuje se stopi lažno pozitivnih rezultata (false positive rate), jer je pogrešno označavanje ljudskog teksta kao AI-generisanog osetljivije od propuštanja AI teksta.

6. Tehnologije

- Python 3
- pandas, numpy
- scikit-learn
- PyTorch
- matplotlib
- Jupyter Notebook

7. Primeri postojećih rešenja

- **GPTZero** — komercijalni detektor koji koristi perplexnost i burstiness teksta:

<https://gptzero.me>

- **Kaggle LLM Detect AI Generated Text** — takmičenje sa javnim rešenjima:

<https://www.kaggle.com/competitions/llm-detect-ai-generated-text/code>

8. Relevantna literatura

- **scikit-learn dokumentacija za Naivni Bajes** — https://scikit-learn.org/stable/modules/naive_bayes.html
- **scikit-learn dokumentacija za K-NN** — <https://scikit-learn.org/stable/modules/neighbors.html>
- **PyTorch dokumentacija — Neural Networks tutorial** — https://pytorch.org/tutorials/beginner/blitz/neural_networks_tutorial.html
- **Towards Data Science — AI Text Detection** — <https://towardsdatascience.com/how-to-detect-ai-generated-text-using-machine-learning>